

Курс «ML и Causal Inference»-Задание 1.

Вы пришли в компанию Izon в роли Head of Data Science. CEO активно говорит о необходимости внедрения AI, но в реальности это происходит хаотично (иными словами, у CEO нет vision, понимания scope of work, целей и задач, сроков и общей стратегии развития направления DS – видимо, поэтому закрывать эти дыры и нанят Head of Data Science). Несколько команд уже запустили ML-модели (рекомендательные системы, ранжирование, динамическое ценообразование), но большинство аналитических инициатив (прогнозирование оттока, LTV, персонализация рассылок и т. д.) не дошли до продакшена или не принесли заметного эффекта (Q1: почему не дошли до продакшена? – не показали статистически достоверных результатов? Низкое качество данных? Недостоверные модели? Неудачные гипотезы? Недостаток компетенций команд для разработки этого типа моделей?

Q2: И почему те, что дошли до продакшена, не принесли заметного – финансового значимого для бизнеса – эффекта?

Вообщем, деньги и время потратили, окупаемости и полезности не получили).

C-level раз в полгода утверждает приоритетные инициативы, среди которых часто фигурируют “внедрение AI” или “использование ML для роста выручки”, но критерии выбора проектов не прозрачны. Часто идеи приходят от топ-менеджмента в формате “давайте сделаем как у Amazon”, реже – от аналитиков и продуктовых команд. (иными словами, 1) у CEO наглядно-визуальный критерий отбора, (visual example)-like; 2) решения принимаются нерационально – на основе личного доверия CEO к мнению (высоко вероятно, но все же не 100%) дилетантов или любителей без core квалификации в DS, а не специалистов с экспертизой в предметной области; 3) можно предположить, что выбор проекта для финансирования AI зависит от степени влияния на CEO соответствующего топ-менеджера отдела и является спонтанным решением, а не запланированной частью общего roadmapa; 4) отношения между задачами, пришедшими от разных топ-менеджеров/отделов и проектов – по общему контексту ситуации, скорее, конкурирующие (за финансовые ресурсы и время специалистов-исполнителей) – в чем есть риск избыточных затрат из-за

несогласованности планирования /выделения человеко-ресурсов, - что является фактором риска потенциального выгорания специалистов, разрывающих свое внимание на несколько разных задач от разных проектов и стейкхолдеров с несогласованными и неприоритизированными целями.

В компании:

- Нет единого ML-пайплайна, инфраструктуры и стандартов

(Привести работу к единому стандарту: унифицировать подход к решению задач, создать единый ML-пайплайн, инфраструктуру и общую базу знаний Knowledge base со стандартами, наладить sharing экспертизы /изучение и внедрение Best practices, провести обучение сотрудников и утвердить общий roadmap)

- Есть команда ML-инженеров, отдельные DS, а также по продуктовому аналитику в каждой продуктовой команде. Но все они работают изолированно друг от друга

(Обучить всех единому подходу, дать разумное время на transition в новый стиль работы. Наладить коммуникацию, закрепить за каждым продуктом свою команду из ML, DS и PA.)

- Большинство аналитических моделей обучаются ad-hoc и не переиспользуются

(Провести CasualDiscovery, чтобы понять, частью каких более высокоуровневых задач являются эти ad-hoc'и, проранжировать эти высокоуровневые задачи по степени финансовой полезности и частоты повторяемости для бизнеса, и вкладываться в те задачи, которые имеют потенциал финансового роста или влияют на факторы, обеспечивающие финансовый рост, в том числе устраняют блокеры роста)

- Оценка качества и влияния моделей происходит с помощью A/B тестирования

(NO: не все типы задач можно решать с помощью исключительно A/B, это искусственный constraint, ограничивающий возможности роста и проверки гипотез и монетизации – в частности поэтому «большинство аналитических инициатив (прогнозирование оттока – задача бинарной классификации, LTV – задача линейной регрессии,

персонализация рассылок – задача категоризации предпочтений пользователей и ранжирования рекомендаций и т. д.) не дошли до продакшена или не принесли заметного эффекта»)

- Сами A/B довольно распространены: более 75 A/B в год разными командам
(Хорошая новость: команды любопытны и data driven ориентированы; плохая новость: недообучены в плане репертуара методов, плюс, возможно, в части задач - неправомерное использование A/B, из-за чего «большинство аналитических инициатив ... не принесли заметного эффекта», т.к. A/B для них и не предназначено или неинформативно в плане выявления зависимостей и эффектов влияния)
- Данные фрагментированы, часть хранится в логах разных СУБД, легаси часть – в excel и забивается вручную
(Создать единое хранилище данных, в которое автоматически с заданной периодичностью добавляются обновления, которые читаются из всех фрагментов. Зоопарк фрагментов за разумное время свести к минимально архитектурно обоснованному минимуму. Ввести политики валидации данных, разграничения уровней доступа к данным, резервное копирование для восстановления в случае повреждения данных и сбоев.)
- У сотрудников разный уровень понимания ML и причинно-следственного анализа (в среднем ниже рынка)
(Дообучить – запланировать время на повышение квалификации ЛПР, обучение сотрудников и выделить на это бюджет времени и денег, в т.ч. и с привлечением внешних консультантов для обучения, а на ключевые роли нанять экспертов, разделяющих общую культуру и способных решать задачи уровня «как в Amazon»).

При этом CEO готов инвестировать в ML, если будет понятен бизнес-эффект.

(Выяснить, какой горизонт планирования у CEO, и подобрать quick-win задачи, которые можно решить и продемонстрировать эффект в пределах этого горизонта планирования / или разумного времени, если горизонт нереалистично относительно возможностей короткий.)

Вас наняли, чтобы выстроить ML и Causal Inference культуру (дать компании ценность в формировании единого стандарта работы), повысить ROI от моделей (добиться, чтобы инвестиции и расходы окупались, финансовая отдача от использования ML выросла) и сделать принятие решений более обоснованным (сформировать roadmap и стратегию принятия решений по внедрению ML).

Продумайте стратегию трансформации.

Вспомогательные вопросы:

1. На каком этапе развития ML находится компания? Почему?

Дать оценку компании сложно, т.к. развитие ML в разных командах неоднородно:

«Несколько команд уже запустили ML-модели (рекомендательные системы, ранжирование, динамическое ценообразование)». В этих нескольких командах развитие ML находится на этапе не ниже 5, experiment driven (ML+A/B) - по условию задачи, есть A/B и некоторые ML-модели, которые не достигают уровня персонализации, - разумеется, при условии, что именно эти модели вышли в продакшен (в условии об этом явно не сказано, мы можем косвенно с допущением предполагать, - на основании информации, что только часть аналитических инициатив дошли до продакшена). И также мы не имеем точной информации из условия задачи, являются ли эти модели User learning driven (7) или они просто learning driven (6).

В то же время «большинство аналитических инициатив (прогнозирование оттока, LTV, персонализация рассылок и т. д. - тут перечисление кейсов уровней 6 и 7) не дошли до продакшена или не принесли заметного эффекта» - это уровень ниже Data driven (4) с признаком "ML в проде", но выше 0-1-2, - т.к. ML есть, но он еще не в проде, а на стадии PoC, т.е. data informed (3).

Итого:

«большинство аналитических инициатив» в компании находятся на уровне data informed (3), при этом «несколько команд» вырвались на уровень experiment driven (5) в использовании A/B

и отдельных моделей и, возможно, в отдельных задачах штурмуют уровни 6 или 7.

Исходя из того, что в целом на уровне компании единой ML-культуры и методологии нет, а достижения отдельных команд носят бессистемный характер положительного эксцесса, оцениваем компанию как целое по методике «группа идет по последнему туристу» - т.е. data informed (3).

2. Каких ключевых элементов не хватает для перехода на следующий качественный уровень?

Компании в целом: не хватает единой культуры, методологии и стандартов, т.е. глобально - образования и достаточных компетенций.

Для того, чтобы перейти с 3 на следующий 4 этап – необходимо добиться подтверждения практической значимости для бизнеса и статистической достоверности разрабатываемых моделей.

Отдельным командам, которые вырвались вперед среднего уровня компании на как минимум 5 уровень – решить задачи персонализации для пользователей.

3. Какую роль должен играть causal inference в компании?

Поскольку (большинство аналитических инициатив (прогнозирование оттока, LTV, персонализация рассылок и т. д.) не дошли до продакшена или не принесли заметного эффекта), в первую очередь необходимо выявить факторы влияния на финансовые метрики и оценить их эффект. Далее искать точки роста и показывать их value для бизнеса, получая поэтапное инвестирование на новые челленджи.

A/B тесты, которыми оперирует компания, – применимы для отдельных частных задач, но не покрывают все потребности компании в оптимизации финансовой выгоды.

Задача causal inference – найти хотя бы одну (лучше – больше одной) задачу, решение которой даст бизнесу максимальную финансово значимую выгоду ощутимого масштаба и в минимальные сроки.

4. Какие use-cases ML/CI стоит развивать в первые 6–12 месяцев? Переведите бизнес-задачи в ML-задачи.

В задаче нет описания бизнес-процессов продуктов компании, не ясна стадия жизненного цикла компании и продуктов, не обозначены соответствующие этапам цели развития, поэтому модель(и) и задачи монетизации нам неизвестны. Без знания

конкретной специфики бизнеса и этой информации предложить точный набор метрик затруднительно, однако мы знаем, что в любом случае – «**It is all about money!**» – соответственно, ориентируемся на метрики, оценивающие финансовый эффект, метрики работы с пользователями (привлечение, вовлеченность и удержание пользователей, уменьшение оттока), в частности, рост LTV от активных пользователей и суммарный GMV, а также ROI.

Для перечисленных в задаче фич я бы предложила такие метрики: *рекомендательные системы* – оценка конверсии CR рекомендаций в целевое действие, опционально – в покупку, также оценка общего объема прибыли по всем клиентам;
в этом кейсе:

object – пользователь,
target1 – conversion rate (CR) – задача бинарной классификации,
target2 – GMV – задача, скорее всего, линейной регрессии.

Другие фичи:

динамическое ценообразование – оценка роста полученной дельты прибыли на одного клиента после введения изменений (задача CI), также оценка общего объема прибыли по всем клиентам (задача линейной регрессии);

прогнозирование оттока – churn rate, динамика удержания и оценка финансовой выгоды с клиентов, которых удалось удержать от оттока;

LTV – оценка этой метрики плюс стратегия ее роста, плюс стратегия дальнейшего удержания лояльных клиентов после того, как эта прогнозная цифра будет достигнута для значимого процента пользователей, – лояльных платежеспособных клиентов на что-то (например, новый продукт в семействе продуктов) нужно переориентировать, чтобы такие клиенты продлились после прогнозируемого LT и продолжали нести деньги, пока мы крутим модели, тестируем отклики в поведении пользователей на изменения и улучшаем пользовательский опыт в отдельном продукте;

персонализация рассылок – оценка CR по целевым действиям, опционально – конвертированным в деньги.

В дальнейшем, при накоплении достаточного количества простых quick-win кейсов в качестве подтверждения полезности, можно

предложить для имплементации кейс, который фактически волнует CEO – профит от внедрения ML, и наглядно отразить на дашбордах динамику метрик окупаемости инвестиций в ML по временным периодам: чистая прибыль в абсолютном выражении от внедрения ML, чистая прибыль от ML относительно затрат на ML (ROI для ML).

5. Какие проблемы вы видите в текущих процессах?

Хаотичность и непоследовательность в принятии решений - CEO; конкуренция за ресурсы/выделяемые на ML инвестиции, принятие решений дилетантами в DS – топ-менеджмент; недостаток компетенций в DS – на уровне исполнителей.

6. Как выстроить взаимодействие между командами?

Как вариант: двойная организационная структура, деление на департаменты по принципу профессиональных ролей (Dev-департамент, QA-департамент, DS-департамент итп) и более краткосрочное – по принадлежности к проекту/стриму. Соответственно, knowledge transfer происходит не только внутри проекта, но и среди коллег из департамента, к которому принадлежит каждый специалист, по темам их профессиональной тематики.

7. Как вы будете обосновывать инвестиции в ML?

Через ROI – окупаемость расходов и ценность полученных инсайтов для прибыли бизнеса.

8. Оцените примерный Roadmap и сроки трансформации

Roadmap:

- привлечение квалифицированных кадров и обучение (Подбор ключевых кадров на позиции между *Head of Data Science* и *Senior* (очевидно по условию задачи, джуниоры и миды с фрагментарным опытом в ML есть, а на позициях, начиная с сениоров и выше – дефицит экспертизы) – 1-3 месяца. Обучение и повышение квалификации – 1-3 месяца до крепкого базового уровня, включающего понимание и способность работать в единых стандартах всех членов команд).
- унификация стандартов работы. Сроки: 1-3 месяца, до 6 мес.
- перестройка процессов принятия решения (предлагать идеи, высказывать хотелки и создавать задачи для DS отдела представители топ-менеджмента могут, однако вмешиваться ввиду недостатка экспертизы в предметной области в принятие решений о приоритизации задач или способы их решения – нет, их голос имеет совещательную ценность на стадии

обсуждения проблем, но не законодательную, - решения, требующие экспертизы в ML, принимаются на уровне DS отдела). - Сроки в идеале минимальные, сразу < 1 месяца, но в реальности топ-менеджмент будет сопротивляться, на сопротивление заложим до 6 мес., т.к. на слом предыдущей модели принятия решений можно надеяться после первых quick-win результатов (3-6 мес.). - сбор и ранжирование задач по мере их финансовой ценности для бизнеса, выявление зависимостей, планирование последовательности решения. Отбор задач для quick-win демо. Сроки - 1-3 месяца.

- quick-win стадия - (1-3)-6 мес.
- более глубокая и систематичная работа - 6-12+ месяцев.

Горизонт планирования трансформации - 1 год. Фактически может понадобиться больше времени на перестройку и сетап процессов и адаптацию к изменениям.

Комментарии:

- Вопросы – это ориентир, а не чеклист. Вы можете структурировать ответ по-своему.
- Делайте обоснованные предположения – это важная часть задания.
- Ваша цель – написать **краткую, но емкую стратегию**, которую сможет понять и принять бизнес.
- Представьте, что этот документ станет основой трансформации компании.

Задание 2 (опционально)

1. Опишите в качестве кейса ваше текущее место работы.

В качестве кейса – последний проект, на котором работала в роли ВА перед глобальным сокращением.

Необходимо построить платформу, которая позволяла бы решить вопрос внутреннего отбора и переквалификации специалистов в другие роли в кратчайшие сроки. Платформа позволяет осуществлять как отбор кандидатов, подходящих для роли, во

внутренней базе, так и их последующее контролируемое самообучение с итоговой квалификацией/экзаменом и утверждением на новую роль.

Сложности для построения рекомендательной модели: в этом направлении нет достаточного объема накопленных исторических данных, по которым можно было бы выделить признаки успешных кейсов смены ролей – не на чем обучать модель. Проект в стадии пилота, успешные кейсы перехода в новую роль уже есть, но вывести из них закономерности (по разным job_title) пока невозможно (на момент постановки задачи).

Модель, используемую для решения смежной кадровой задачи – рекомендации кандидатов в проекты на роль в соответствии с их job_title и предыдущим опытом, зафиксированном в системе, по утверждению команды DS, кастомизировать и применить под кейс со сменой роли не получится.

Также, – мое предположение, – с учетом отсутствия систематизированных исторических данных, необходимо придумать как обогащать алгоритм отбора кандидатов, исключавший бы вырождение модели к постоянному воспроизводству тех первых признаков, которые модель возьмет из первой выборки за основу для дальнейшего тиражирования по принципу (атрибуты первой тестовой выборки)-like, чтобы кандидаты, которые по своим способностям и сильным сторонам могли бы принести пользу в новой роли, вообще могли бы быть замечены и попасть в воронку рекомендаций, даже если формально они не совпадают по атрибутам с кандидатами предыдущей выборки. Проблема рекомендательных систем в замкнутом контуре – то, что они заклиниваются на прошлом и его воспроизведении в образ будущего, что является constraint'ом, ограничивающим возможности! (Это как генетическое вырождение до непригодного для дальнейшего воспроизведения брака в условиях постоянного близкородственного скрещивания генов – нужен постоянный приток новой крови, чтобы процент брака был минимален). Ошибки предсказания растут, точность падает!

Декомпозиция задачи:

1) необходимо провести CasualDiscovery и выявить атрибуты, по которым модель будет обучаться строить прогноз – при этом, у каждого пользователя в системе существует несколько десятков описывающих его атрибутов.

2) необходимо также провести анализ, какой объем выборки (и с каким набором ключевых атрибутов) необходим для обучения новой модели.

3) необходимо найти способ самообучения модели на новых признаках кандидатов, которые не входят в начальный тестовый набор и итеративное расширение набора этих признаков, чтобы модель позволяла выявлять талантливых кандидатов с признаками за пределами начальной тестовой выборки, а не схлопываться в прогнозах на специфическом наборе ограниченных признаков (исторические атрибуты нулевой итерации)-like, отбраковывая талантливых за непопадание в самозакрепляющийся шаблон, построенный на первоначальных итерациях.

4) важно уделить внимание качеству данных, точности модели и уровню ошибок и не выпускать в продакшен модель с признаками предиктивного вырождения!

Честно скажу, что продвинуться с этими задачами я сильно не успела из-за дефицита времени, т.к. близился уже заранее известный момент сокращения штата (нотификация за 2 месяца), а задача, которой я занималась, была на стадии discovery. Но я к ней периодически мысленно возвращаюсь, - она интересна мне своей нетривиальностью и уровнем сложности.

2. Представьте, что вы на руководящей позиции. Продумайте стратегию развития ML-культуры, опираясь на те же вспомогательные вопросы из задания 1.

ML-культура в компании была на высоком уровне - 6.

Единственный момент, который бы я исправила - отсутствие кастомизации под пользователя (специалиста, который ищет новый проект или роль, в контексте кадровых задач с метчингом) - это решить проблему «самовоспроизводящегося пророчества» - предвзятости рекомендаций будущих ролей и проектов на основе постоянного тиражирования вектора прошлого опыта и тех технологий, которые взяты как предиктивные атрибуты из формального описания прошлых проектов.

(В результате чего - как пример повторявшегося паттерна - получалось, что являясь много лет аналитиком, я не получаю разнообразия вариантов по аналитике даже в круге близкого

радиуса к моему предыдущему образовательному бекграунду, опыту решавшихся задач или вектору self-learning'a в системе (в бизнес-анализе, моделировании поведения пользователей, анализе числовых зависимостей и закономерностей, статистических методах, или в project management), как и по желаемым смежным направлениям аналитики, хотя такие предложения в системе заведомо существуют, но при этом охват вариантов по совершенно далеким от аналитики специальностям – от девелопера до архитектора и девопса или автоматизатора – на основании формальных атрибутов, характеризующих не мои таланты, а сами бывшие проекты и их архитектуру и технологии в описаниях, - в огромном избытке!

Я считаю это ошибочным подходом, создающим искусственный стеклянный потолок специалистам в профессиональном треке – гипертрофированное консервирование на воспроизведении прошлого, из которого система не даст шанса выпрыгнуть в альтернативные и более продуктивные/мотивирующие развитие варианты направлений, проектов и ролей, отличающиеся от предыдущих исторических данных, когда и если специалист сам этого хочет.

Технически для этого улучшения нужна перестройка алгоритма модели рекомендаций.

- система рекомендаций должна самообучаться в разметке данных (проводя итеративное переосмысление набора и количества like-атрибутов и их весовых коэффициентов);
- атрибуты профессионального вектора пользователя должны сопоставляться пользователю корректно и коррелировать с матрицей скиллов его роли, навыками (в т.ч. - смежными), образованием и персональными целями и индивидуальным планом развития, причем план индивидуального профессионального развития с соответствующими атрибутами должен иметь приоритет (более значимый вес) над любым экземпляром experience'a из прошлой истории;
- на старте моделирования система должна предоставлять объекту (кандидат в данном случае) самостоятельно сетапить в системе профессиональную цель и круг задач (как по роли и задачам, вектору образования, талантов и интересов, так и – в меньшей степени - по вариабельным переменным типа языков программирования, технологий и иным существенным атрибутам, самостоятельно задавая им веса как персонально оцениваемую

важность в будущем векторе).

Не модель должна решать за специалиста, чем ему лучше заниматься, задалбывая его бесконечной рекурсией на основе рандомно и директивно назначенных ему проектов из прошлого, которые он не выбирал или уже давно перерос, - а он сам, исходя из целей, личных способностей и вектора своих собственных интересов в будущем!!!

В пирамиде уровней data driven'ости не хватает вишенки на торте - 8. актуализации авторской позиции пользователя в ML (трансформации роли пользователя из объекта моделирования в субъект, управляющий моделированием) - предоставления пользователю возможности самому управлять параметрами рекомендательной системы, моделирующей варианты предложений для него самого.

Р. С. Я специально ставлю вас на руководящие позиции, чтобы вы почувствовали власть в своих руках и возможность влиять на решения.

Ох, если бы! ☺ - Первым делом я бы исправила хромящие модели и заложенные в них biases!

Дерзайте!